TECH CHALLENGE

# 9IADT – FASE 3

# dIAbetes



Assistente Médico com LLM Fine-tuned, Prontuário, RAG e LangGraph

Thiago de Melo Lima – RM370763

# DESCRIÇÃO DO ASSISTENTE MÉDICO

Solução com LLM fine-tuned, Prontuário, RAG e LangGraph

Assistente médico especializado em diabetes que integra o conhecimento clínico do modelo fine-tuned, dados do prontuário do paciente e informações recuperadas via RAG para gerar respostas seguras, contextualizadas e baseadas em evidências.

## FONTES DE CONHECIMENTO

### LLM FINE-TUNED

Modelo Llama 3.2 3B fine-tuned com dados médicos sobre diabetes.

Conhecimento especializado.

### PRONTUÁRIO

Dados estruturados do paciente (exames, histórico, medicamentos, diagnósticos, etc.).

Informação atual e contextual.

### RAG (BASE DOCUMENTAL)

Manual de contagem de carboidratos e outros documentos clínicos. Recuperação de trechos relevantes.

Evidências e diretrizes atualizadas.

## ARQUITETURA DA SOLUÇÃO

### ORQUESTRAÇÃO COM LANGGRAPH

**1. CLASSIFICAÇÃO DA CONSULTA**

LangGraph classifica o tipo de pergunta e decide quais fontes consultar.

**2. SELEÇÃO DAS FONTES**

Seleciona LLM fine-tuned, Prontuário e/ou RAG conforme a necessidade da consulta.

**3. CONSOLIDAÇÃO DO CONTEXTO**

LangGraph consolida as informações das fontes em um contexto único e relevante.

### LLM FINE-TUNED

Geração da resposta com base no contexto consolidado e nas regras de segurança.

### RESPOSTA AO USUÁRIO

Resposta clara, objetiva e baseada em evidências.

Inclui explicação e fontes utilizadas.

## SEGURANÇA E REGRAS

- Não realiza diagnóstico definitivo.
- Não prescreve medicamentos.
- Respostas apenas informativas.
- Sempre recomenda avaliação de um profissional de saúde.
- Mantém confidencialidade e privacidade dos dados.
- Logs de todas as interações para auditoria.

## APRESENTAÇÃO DAS FONTES

- Indica de onde a informação foi obtida.
- Para RAG, apresenta o título do documento e a página.
- Transparência e explainability em todas as respostas.

## EXEMPLOS DE CONSULTAS E FONTES UTILIZADAS

"Quais alimentos têm 15g de carboidrato?"

Fontes utilizadas: LLM Fine-tuned + RAG

"Qual foi o último exame de HbA1c do paciente?"

Fontes utilizadas: LLM Fine-tuned + Prontuário

"O que significa hipoglicemia e quais os sinais?"

Fontes utilizadas: LLM Fine-tuned

"Quais alimentos posso comer no café da manhã?"

Fontes utilizadas: LLM Fine-tuned + RAG + Prontuário

**FOCO DA SOLUÇÃO:** fornecer respostas seguras, contextualizadas e baseadas em evidências para apoiar profissionais de saúde no cuidado de pacientes com diabetes, combinando conhecimento especializado, dados individuais e diretrizes clínicas atualizadas.

# EXPLICAÇÃO DO PROCESSO DE FINE-TUNING

Especialização da LLM no domínio de Diabetes

## 1 MODELO UTILIZADO

Modelo open source utilizado como base para o fine-tuning.

**Llama 3.2 3B Instruct**

via Unsloth (4-bit)

Contexto: 2048 tokens

LoRA / PEFT
r = 16

Treinável: 0.75%

## 2 DADOS MÉDICOS

Dataset MedQuAD filtrado para temas relacionados a diabetes.

| | |
|---|---|
| Arquivos XML processados | 157 |
| Registros brutos | 157 |
| Após filtros (diabetes) | 135 |
| Após deduplicação | 135 |

Perguntas e respostas estruturadas em formato conversacional (User / Assistant)

## 3 PREPARAÇÃO DOS DADOS

Curadoria, limpeza e transformação para fine-tuning.

- Limpeza e padronização das perguntas e respostas
- Conversacionalização: formato de mensagens (User / Assistant)
- Anonimização e remoção de informações sensíveis
- Dataset salvo em JSONL e CSV

## 4 FINE-TUNING

Treinamento do modelo para especialização no domínio de diabetes.

**Configuração do treinamento**

- Épocas: 3
- Batch size: 2
- Grad. Acumulação: 4 (Batch efetivo: 8)
- Learning rate: 2e-4
- Otimizador: AdamW 8-bit
- Scheduler: Linear
- Weight decay: 0.001
- FP16 / BF16 (auto)
- Warmup steps: 5
- Max seq. length: 2048
- Checkpoints a cada 10 passos

## 5 AVALIAÇÃO QUALITATIVA

Testes para validar o comportamento da LLM especializada.

- What is Type 2 diabetes?
- What is hypoglycemia?
- What is diabetic neuropathy?
- How can diabetes be prevented?

Respostas claras, objetivas e baseadas em evidências médicas.

## 6 MODELO FINE-TUNED

Modelo especializado e pronto para uso no assistente médico.

**llama32_diabetes_lora**

Modelo + Tokenizador salvos

Modelo (LoRA) Tokenizer

Pronto para integração com LangGraph

## RESUMO DO PROCESSO

Coleta de dados médicos (MedQuAD) → Filtragem para temas de diabetes → Transformação para formato conversacional → Fine-tuning com LoRA (Unsloth) → Avaliação qualitativa das respostas → Modelo especializado pronto para uso

## OBJETIVO

Expecializar a LLM em conhecimento médico sobre diabetes para fornecer respostas mais precisas, seguras e contextualizadas no assistente médico.

**FINE-TUNING COM EFICIÊNCIA:** Utilizamos LoRA e quantização 4-bit para reduzir o consumo de memória e permitir o treinamento em GPU de uso pessoal, mantendo qualidade e performance na especialização do modelo.

# RAG – RECUPERAÇÃO DE INFORMAÇÕES CLÍNICAS

## Processo de construção e utilização da base de conhecimento

O RAG (Retrieval Augmented Generation) permite recuperar informações atualizadas do Manual de Contagem de Carboidratos e outros documentos clínicos para complementar o conhecimento da LLM fine-tuned e gerar respostas mais precisas e baseadas em evidências.

### 1 COLETA DO DOCUMENTO

Manual de Contagem de Carboidratos para Pessoas com Diabetes (109 páginas) no formato PDF.

PDF

manual_contagem_carboidratos.pdf

109 páginas

### 2 CLASSIFICAÇÃO DAS PÁGINAS

Separação do documento em três tipos de conteúdo para tratamento adequado.

- Texto explicativo — Páginas 1 – 49
- Tabela de alimentos — Páginas 50 – 91
- Tabela de festas — Páginas 92 – 109

### 3 EXTRAÇÃO E ESTRUTURAÇÃO

Extração do conteúdo e estruturação de tabelas em formato padronizado.

- **Textos explicativos** — Chunking por semelhança (800 tokens / overlap 120)
- **Tabelas** — Extração de alimentos, medidas e carboidratos em linhas estruturadas

### 4 GERAÇÃO DE EMBEDDINGS

Conversão dos chunks e registros estruturados em vetores semânticos.

Modelo de embeddings (all-MiniLM-L6-v2)

[0.12, -0.45, 0.78, ...]

Vetores semânticos

### 5 ARMAZENAMENTO VETORIAL

Índices vetoriais salvos no ChromaDB para busca de alta performance.

ChromaDB

Coleção de vetores persistente em disco

- ✓ Textos explicativos
- ✓ Tabela de alimentos
- ✓ Tabela de festas

### 6 RECUPERAÇÃO NA CONSULTA

Busca semântica retorna os chunks mais relevantes para a pergunta do usuário.

Busca semântica

↓

Top-k resultados relevantes

Contexto recuperado para a LLM

## FONTES DO CONHECIMENTO UTILIZADAS NO RAG

**Manual de Contagem de Carboidratos para Pessoas com Diabetes**

Conteúdo processado:

- Textos explicativos (páginas 1–49)
  → Chunking semântico
- Tabela de alimentos (páginas 50–91)
  → Estruturada em linhas de alimentos, medidas e carboidratos
- Tabela de festas (páginas 92–109)
  → Estruturada em linhas de alimentos, medidas e carboidratos

**Exemplo de linha estruturada da tabela de alimentos**

| Alimento | Medida Usual | Carboidratos (g) | Página |
|---|---|---|---|
| Arroz branco cozido | 3 colheres de sopa | 15 | 54 |
| Feijão carioca cozido | 1 concha média | 15 | 55 |
| Maçã com casca | 1 unidade média | 15 | 56 |
| ... | ... | ... | ... |

Total de registros estruturados da tabela de alimentos: milhares de linhas

## BENEFÍCIOS DO RAG NA SOLUÇÃO

- **Informações atualizadas** — Respostas baseadas em documentos clínicos confiáveis e atualizados.
- **Menos alucinações** — A LLM utiliza apenas informações recuperadas dos documentos.
- **Respostas mais precisas** — Busca semântica encontra o conteúdo exato mais relevante para cada pergunta.
- **Transparência e auditoria** — As fontes utilizadas são apresentadas em cada resposta.

## FLUXO DE USO DO RAG NA GERAÇÃO DA RESPOSTA

Pergunta do usuário → Busca semântica no ChromaDB → Recuperação dos Top-k documentos → Contexto consolidado + regras de segurança → LLM fine-tuned gera a resposta → Resposta com fontes apresentadas

## EXEMPLO DE APRESENTAÇÃO DE FONTES

Segundo o Manual de Contagem de Carboidratos (p. 54), "3 colheres de sopa de arroz branco cozido contêm aproximadamente 15g de carboidratos."

Fontes: manual_contagem_carboidratos.pdf (p. 54)

# DIAGRAMA DO FLUXO LANGCHAIN

Do recebimento da pergunta à resposta final da LLM

O fluxo orquestra as decisões sobre quais fontes de conhecimento utilizar (Prontuário, RAG e/ou Conhecimento Geral) para montar o contexto mais relevante e gerar respostas precisas, seguras e baseadas em evidências.

## FONTES DE CONHECIMENTO

### PRONTUÁRIO

Dados estruturados do paciente (exames, histórico, medicamentos, diagnósticos, etc.).

Informação atual e individual.

### RAG (BASE DOCUMENTAL)

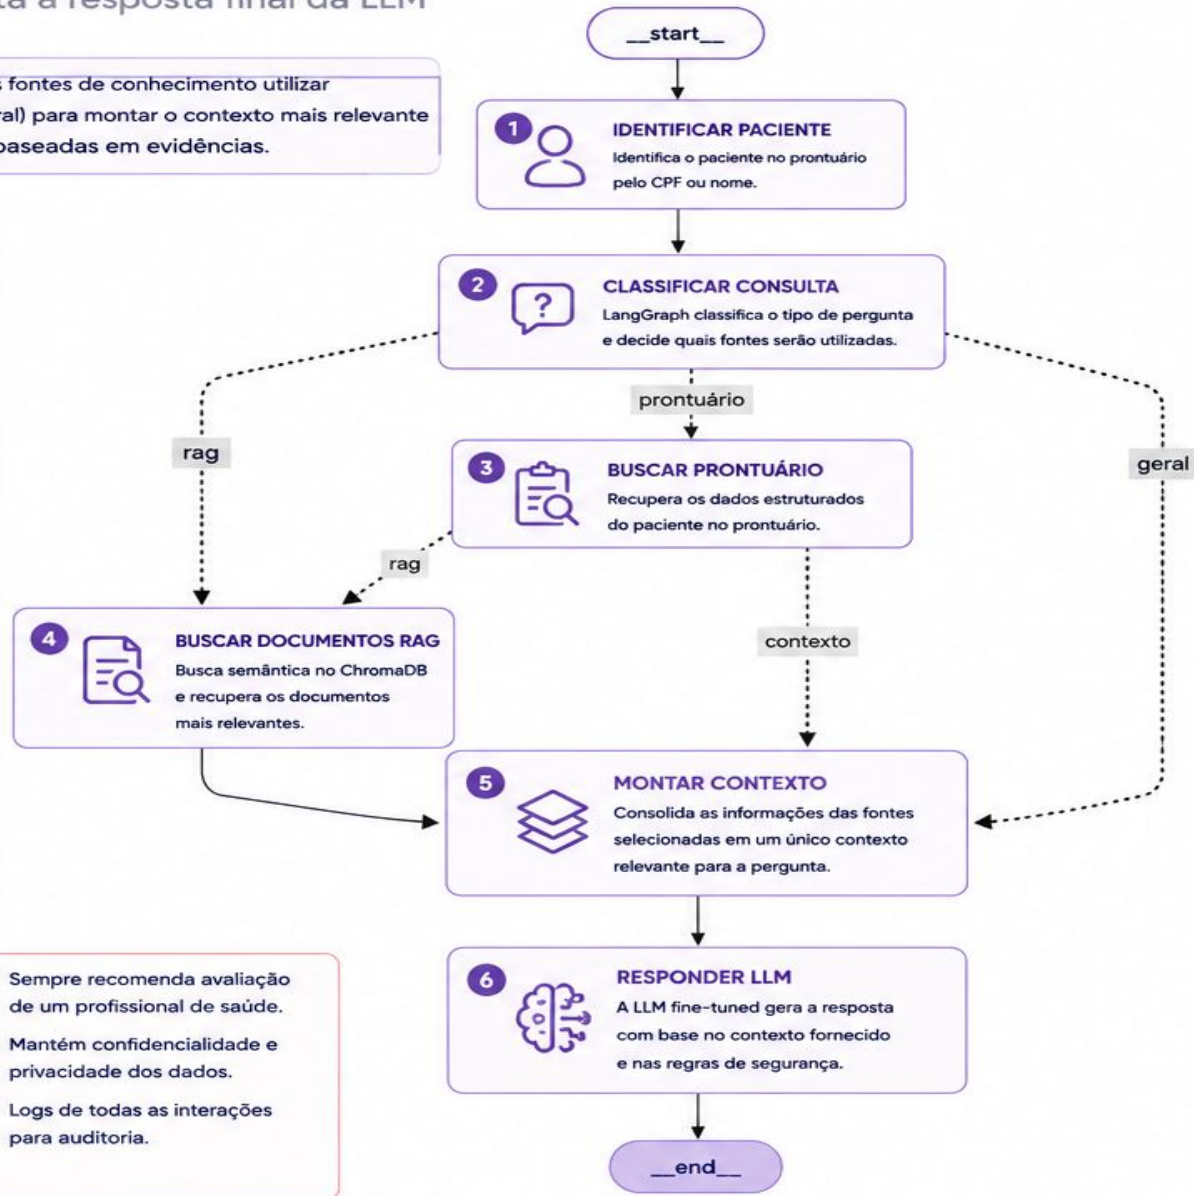
Base documental em vetores (ChromaDB) com conteúdo clínico e nutricional.

Evidências e diretrizes atualizadas.

### CONHECIMENTO GERAL DA LLM

Conhecimento médico especializado adquirido no fine-tuning.

Informações gerais sobre diabetes e boas práticas clínicas.




## REGRAS DE SEGURANÇA

- Não realiza diagnóstico definitivo.
- Não prescreve medicamentos.
- Respostas apenas informativas.
- Sempre recomenda avaliação de um profissional de saúde.
- Mantém confidencialidade e privacidade dos dados.
- Logs de todas as interações para auditoria.

## LEGENDA DO FLUXO

1. **Identificar Paciente**
   Busca o paciente informado na pergunta.
2. **Classificar Consulta**
   Define o tipo de pergunta e decide quais fontes serão utilizadas.
3. **Buscar Prontuário**
   Recupera os dados estruturados do paciente no prontuário.
4. **Buscar Documentos RAG**
   Realiza busca semântica na base documental (ChromaDB).
5. **Montar Contexto**
   Une todas as informações relevantes em um contexto único.
6. **Responder LLM**
   Gera a resposta final com base no contexto e nas regras de segurança.

## TIPOS DE CONSULTA E FONTES UTILIZADAS

| | |
|---|---|
| Prontuário + RAG | Dados do paciente + documentos clínicos |
| Prontuário | Apenas dados do paciente |
| RAG | Apenas base documental |
| Geral | Conhecimento médico da LLM |

## META DADOS E EXPLICABILIDADE

- ✓ Página do documento (RAG)
- ✓ Título do documento
- ✓ Trecho utilizado
- ✓ Data da consulta
- ✓ Dados do paciente (quando aplicável)

O LangGraph permite decisões dinâmicas e rastreáveis sobre o uso das fontes, garantindo respostas contextualizadas, seguras e baseadas em evidências.

# AVALIAÇÃO DO MODELO E ANÁLISE DOS RESULTADOS

Testes do Assistente de IA validando o fluxo LangGraph, segurança e explainability

Realizamos testes com diferentes tipos de consultas para validar o funcionamento do fluxo do LangGraph, a integração entre a LLM customizada, o prontuário e o RAG, além da segurança das respostas e a apresentação das fontes (explainability).

## RESUMO DOS TESTES REALIZADOS

### 1. PERGUNTA GERAL

Consulta sobre conhecimento médico geral, sem referência a paciente específico.

Fonte principal: Conhecimento da LLM

### 2. PERGUNTA CONTEXTUALIZADA

Consulta utilizando apenas os dados estruturados do paciente (no prontuário).

Fonte principal: Prontuário

### 3. PERGUNTA COMBINADA

Consulta que utiliza simultaneamente dados do paciente e informações recuperadas pelo RAG.

Fontes: Prontuário + RAG

## DETALHAMENTO DOS TESTES

### 1 PERGUNTA GERAL

Pergunta realizada:

O que é diabetes tipo 2?

Fluxo executado:

identificar_paciente → classificar_consulta → montar_contexto → responder_llm (conhecimento da LLM)

Resultado obtido (resumo)

A LLM descreveu o diabetes tipo 2 como uma doença crônica caracterizada por alterações no metabolismo da glicose do sangue, resultantes de resistência ou insuficiência da insulina. Explicou que pode ser diagnosticada com testes de glicemia e que os níveis de glicose costumam estar baixos antes de comer e aumentam após as refeições.

**Fontes:** Conhecimento médico especializado (LLM Fine-tuned)

- Paciente identificado: **NÃO**
- Prontuário utilizado: **NÃO**
- RAG utilizado: **NÃO**
- Resposta segura e objetiva
- Fonte apresentada: SIM

### 2 PERGUNTA CONTEXTUALIZADA

Pergunta realizada:

A Maria Silva está com o diabetes controlado considerando seus últimos exames?

Fluxo executado:

identificar_paciente → classificar_consulta → buscar_prontuario → montar_contexto → responder_llm (prontuário)

Resultado obtido (resumo)

A LLM analisou os dados da paciente Maria Silva (diabetes tipo 2 e hipertensão). Informou que seus níveis de glicemia de jejum estão altos (176 mg/dL) e o HbA1c também está elevado (8,4%). Explicou que os medicamentos ajudam a controlar a glicemia, mas não indicam controle adequado. Orientou verificar se a glicemia de jejum está dentro do intervalo normal (70 a 99 mg/dL).

**Fontes:** Prontuário do paciente

- Paciente identificado: **SIM (Maria Silva)**
- Prontuário utilizado: SIM
- RAG utilizado: **NÃO**
- Resposta segura e contextualizada
- Fonte apresentada: SIM

### 3 PERGUNTA COMBINADA

Pergunta realizada:

A Maria Silva precisa melhorar a alimentação. Segundo o manual, quantos carboidratos existem em uma colher de sopa de abobrinha italiana cozida?

Fluxo executado:

identificar_paciente → classificar_consulta → buscar_prontuario + buscar_documentos_rag → montar_contexto → responder_llm

Resultado obtido (resumo)

A LLM utilizou os dados do prontuário e informações do manual (RAG). Informou que, segundo o documento diabetes.pdf (página 61), a abobrinha italiana cozida possui 0 g de carboidratos em uma colher de sopa cheia. Apresentou também outras fontes (páginas 51, 72, 75 e 83) como suporte.

**Fontes:** Prontuário do paciente + Documento médico (RAG - diabetes.pdf)

- Paciente identificado: **SIM (Maria Silva)**
- Prontuário utilizado: SIM
- RAG utilizado: SIM
- Resposta segura e objetiva
- Fontes apresentadas: SIM (6 documentos)

## O QUE FOI AVALIADO

- Funcionamento do fluxo LangGraph
- Direcionamento correto das fontes (RAG e Prontuário)
- Qualidade e segurança das respostas
- Explainability: apresentação das fontes utilizadas
- Respeito às regras de segurança (médicas e de privacidade)

## PRINCIPAIS CONSTATAÇÕES

- O LangGraph direcionou corretamente o fluxo conforme o tipo de consulta.
- As respostas foram claras, objetivas e baseadas em evidências.
- As regras de segurança foram respeitadas: não realiza diagnóstico definitivo e não prescreve medicamentos.
- A explainability apresentou as fontes utilizadas (páginas do documento e dados do prontuário).

## CONCLUSÃO

Os testes comprovam que o assistente utiliza de forma adequada o conhecimento da LLM fine-tuned, os dados do prontuário e o RAG para gerar respostas seguras, contextualizadas e com rastreabilidade das fontes.

Todos os testes foram executados com a LLM customizada para o domínio de diabetes, seguindo as regras de segurança e apresentação das fontes (explainability).

# CONCLUSÃO

O assistente desenvolvido integra uma LLM especializada em diabetes com dados do prontuário do paciente e uma base documental (RAG), orquestrados pelo LangGraph. Essa combinação permite gerar respostas mais precisas, contextualizadas, seguras e baseadas em evidências.

## 1. LLM ESPECIALIZADA E FINE-TUNING

A LLM foi ajustada com dados médicos sobre diabetes, adquirindo conhecimento especializado para fornecer respostas claras, objetivas e baseadas em evidências.

**Modelo base**
Llama 3.2 3B Instruct (4-bit)

**Dataset de fine-tuning**
2.432 exemplos
(perguntas e respostas)

**Técnica utilizada**
LoRA / PEFT (r = 16)
Treinável: 0,75% dos parâmetros

Modelo especializado no domínio de diabetes e otimizado para inferência eficiente.

## 2. ARQUITETURA DO ASSISTENTE COM LANGGRAPH

O LangGraph orquestra o fluxo dinâmico do assistente, direcionando a consulta para as fontes apropriadas e consolidando o contexto para a LLM.

IDENTIFICAR PACIENTE → CLASSIFICAR CONSULTA → ROTEAMENTO DINÂMICO → MONTAR CONTEXTO → RESPONDER LLM

**Tipos de consulta suportados**

- Prontuário + RAG: dados do paciente + documentos clínicos
- Prontuário: apenas dados do paciente
- RAG: apenas base documental
- Geral: conhecimento médico da LLM

Fluxo flexível que utiliza somente as fontes necessárias, garantindo respostas contextualizadas e relevantes.

## 3. RAG COM BASE DOCUMENTAL ESPECIALIZADA

Integração com base documental (manual de alimentos para diabéticos) por meio de busca semântica na ChromaDB, recuperando informações nutricionais precisas e atualizadas.

**Documentos processados**
110 páginas (PDF)

**Base vetorial**
ChromaDB

**Tipos de conteúdo**
Texto clínico, tabela de alimentos e festas/comemorações

Respostas fundamentadas em documentos confiáveis, com indicação clara das fontes (páginas e trechos).

## BENEFÍCIOS ALCANÇADOS

**MAIOR PRECISÃO**
Respostas mais assertivas combinando conhecimento especializado, dados do paciente e documentos confiáveis.

**SEGURANÇA E CONFIABILIDADE**
Aplicação de regras de segurança que evitam diagnósticos, prescrição e informações não presentes nas fontes.

**EXPLAINABILITY**
Apresentação transparente das fontes utilizadas, incluindo páginas, títulos e trechos.

**SUPORTE À DECISÃO CLÍNICA**
Ferramenta de apoio que auxilia no entendimento do caso e na tomada de decisões mais informadas.

**PRONTO PARA EVOLUIR**
Arquitetura modular e extensível para inclusão de novas fontes, melhorias contínuas e futuras aplicações.

**IMPORTANTE:** A solução deve ser utilizada apenas como ferramenta de apoio, não substituindo a avaliação e o diagnóstico realizados por um profissional de saúde responsável.